Minería de datos y visualización

25 de marzo 2021

CC BY SA

David Tomás Díaz
@d_tomas

Universidad de Alicante

lsi Departamento de Lenguajes y Sistemas Informáticos

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - Datos
  - Características
  - Algoritmos
- …y para saber más

Contenidos

- **La importancia de los datos**
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - Datos
  - Características
  - Algoritmos
- …y para saber más

La importancia de los datos

- Vivimos en un mundo inundado de datos
  - Páginas webs que monitorizan cada clic de sus usuarios
  - Teléfonos móviles acumulando registros de ubicación
  - Vehículos inteligentes recopilando hábitos de conducción
  - Hogares inteligentes recopilando hábitos de vida
  - Tiendas online recopilando hábitos de compra
  - Todo tipo de estadísticas gubernamentales
  - Internet es una enorme enciclopedia
  - El Internet de las cosas (*Internet of Things* - IoT)
  - El yo cuantificado (*Quantified self*)
  - ...

La importancia de los datos

Enterradas en estos datos están las respuestas a incontables preguntas que nadie ha pensado ni siquiera hacer

Contenidos

- La importancia de los datos
- **De los datos al conocimiento**
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - Datos
  - Características
  - Algoritmos
- …y para saber más

De los datos al conocimiento

- Extracción de conocimiento a partir de los datos
  - *Knowledge Discovery in Databases* (KDD)
  - "Extracción no trivial de información implícita, previamente desconocida y potencialmente útil a partir de datos"

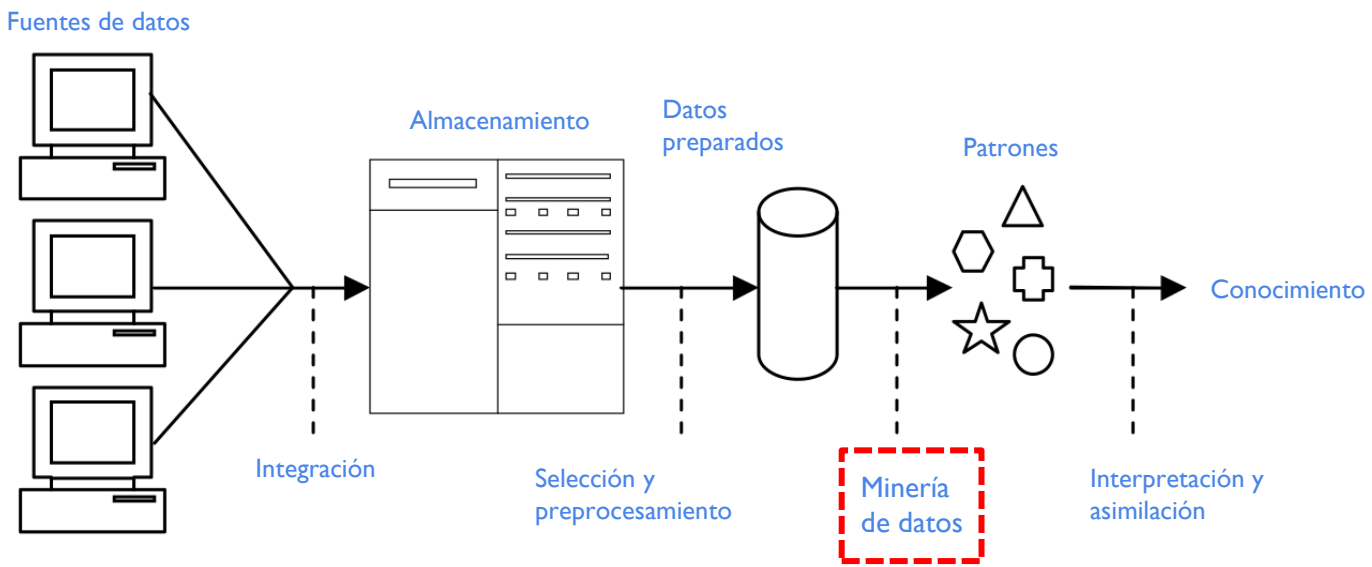

De los datos al conocimiento

- La caja de herramientas del científico de datos
  - *Python* (tu lenguaje favorito de programación)
  - *Google Colab* (tu plataforma favorita de desarrollo)
  - *Pandas* (tu librería favorita para manipular tablas)
  - *NumPy* (tu librería favorita para operar con vectores)
  - *Scikit-learn* (tu librería favorita para *machine learning*)
  - *Seaborn* (tu librería favorita para visualización)
  - *Kaggle* (tu web favorita para juntarte con la gente guapa)

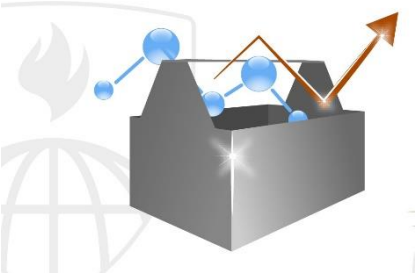

De los datos al conocimiento

- Minería de datos
  - *Data mining*
  - Proceso de descubrir patrones en grandes volúmenes de datos
  - Analogía con un proceso de minería real
    - Partimos de un mineral (datos)
    - Llegamos al producto final refinado (conocimiento)
  - Emplea métodos de aprendizaje automático, estadística y bases de datos

De los datos al conocimiento

- Minería de datos
  - La extracción de conocimiento es un reto debido a la gran disparidad de problemas y tipos de datos existentes
  - Un problema de recomendación de un producto comercial es muy diferente de una aplicación de detección de intrusos
    - Formato de los datos de entrada
    - Definición del problema
  - Incluso dentro de tipos de problemas similares las diferencias son bastante significativas
    - Recomendación de un producto en una base de datos
    - Recomendación de contactos en una red social

De los datos al conocimiento

- Aplicaciones
  - Analizar imágenes de satélite
  - Análisis de compuestos orgánicos
  - Detección de fraude en tarjetas de crédito
  - Predicción de consumo eléctrico
  - Diagnósticos médicos
  - Valoración de inmuebles
  - Marketing dirigido
  - Pronóstico del tiempo
  - Predecir audiencia de televisión
  - …

De los datos al conocimiento

- Ejemplos
  - Facebook
    - Pregunta a los usuarios su ciudad natal y ubicación actual
    - Aparentemente el objetivo es facilitar que tus amigos te encuentren y se conecten contigo
    - También analiza estas ubicaciones para identificar los patrones de migración global y dónde viven los fans de los diferentes equipos de fútbol

De los datos al conocimiento

- Ejemplos
  - Campaña de Obama 2012
    - Empleó a docenas de científicos de datos para identificar votantes que necesitaban atención extra, cuyo voto era más probable que fuera útil
    - Identificaron los programas óptimos de recaudación de fondos específicos para los donantes

De los datos al conocimiento

- Ejemplos
  - OkCupid
    - Hace miles de preguntas a sus miembros (desde el cambio climático al cilantro) para encontrar las parejas más apropiadas
    - Analiza estos resultados para identificar preguntas "inocuas" que hacer para saber qué probabilidad hay de que alguien se acueste contigo en la primera cita

Un inciso

Google Colaboratory

- Entorno gratuito de *Jupyter Notebook* que se ejecuta en la nube de Google (acceso mediante cuenta de Gmail)
  - https://colab.research.google.com
- *Jupyter* es un entorno web interactivo que permite editar y ejecutar código Python
- Podemos ejecutar nuestro código en CPU y GPU en la nube
- Los cuadernos de *Jupyter* se guardan en Google Drive y se pueden compartir como cualquier otro documento
- Tiene algunas limitaciones:
  - Máquina inicial de 12GB de RAM y 100GB de disco duro
  - Tiempo máximo de ejecución: 12 horas
  - Si estamos más de 90 minutos sin usar el cuaderno se desconecta

Google Colaboratory

- Accede a

https://bit.ly/3bZsK8n

- Hazte tu propia copia en Drive

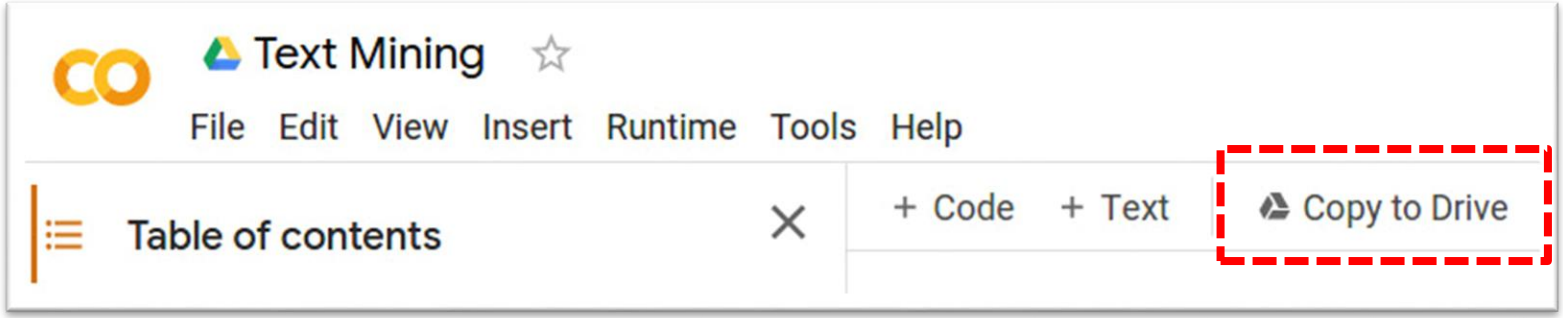

Seguimos

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- **Análisis de datos exploratorio**
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - Datos
  - Características
  - Algoritmos
- …y para saber más

Análisis de datos exploratorio

- Definición
  - *Exploratory Data Analysis*
  - Técnicas para analizar datos mediante tratamiento estadístico
    - Importar, limpiar y validar
    - Visualizar distribuciones
    - Explorar relaciones entre variables
    - Selección de características
    - Identificación de valores extremos
    - …
  - Se utiliza en la fase inicial de todo proyecto de ciencia de datos
  - El objetivo es tener un conocimiento sólido de los datos

Análisis de datos exploratorio

- Tipos de análisis
  - Estadísticas descriptivas
    - Media
    - Mediana
    - Moda
    - Varianza
    - ...
  - Visualización
    - Histograma
    - Diagrama de dispersión
    - Diagrama de caja
    - Nubes de palabras
    - ...

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - **Estadísticas descriptivas**
  - Visualización
- Aprendizaje automático
  - Datos
  - Características
  - Algoritmos
- …y para saber más

Estadísticas descriptivas

- Definición
  - Técnicas matemáticas para resumir o describir conjuntos de datos de manera cuantitativa
  - Identificar propiedades de los datos, ruido y valores extremos
  - Medidas habituales usadas para describir los datos
    - Tendencia central
    - Dispersión

Estadísticas descriptivas

- Tendencia central
  - Las columnas pueden de tener miles de valores distintos
  - Un paso básico al explorar los datos es obtener un valor típico para cada columna
  - Tendencia central: estimación de dónde está localizada la mayoría de los datos
  - Medidas habituales
    - Media
    - Mediana
    - Moda

Estadísticas descriptivas

- Tendencia central
  - Media (*mean*, *average*)
    - Medida más común, aunque sensible a valores extremos

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

  - Mediana (*median*, *50th percentile*)
    - Valor que ocupa la posición central en un conjunto ordenado
    - Si el conjunto de datos es par, será la media de los dos que ocupan esa posición
    - Menos sensible a valores extremos
      - Ej: ingresos en los hogares en la zona donde vive Bill Gates

Estadísticas descriptivas

- Tendencia central
  - Moda (*mode*)
    - El valor o categoría que más se repite en un conjunto de datos
    - Se usa principalmente para datos categoriales
    - Puede haber varias modas en un conjunto
      - Unimodal
      - Bimodal
      - Multimodal

Estadísticas descriptivas

- Dispersión
  - La tendencia central es una forma de resumir una variable
  - Otra forma de hacerlo es mediante la dispersión (variabilidad), midiendo si los valores están agrupados o dispersos
  - Es útil para identificar valores extremos (*outliers*)
  - Medidas habituales
    - Rango
    - Cuantil
    - Desviación media
    - Varianza
    - Desviación estándar

Estadísticas descriptivas

- Dispersión
  - Rango (*range*)
    - Diferencia entre el valor más grande y el más pequeño
    - Es la medida más básica de dispersión
    - Es muy sensible a valores extremos
  - Cuantil (*quantile*)
    - Puntos tomados a intervalos regulares de una distribución que la dividen en conjuntos de igual tamaño
    - *Cuartiles*: dividen la distribución en 4 partes (cuantil 0.25, 0.50 y 0.75)
    - *Percentiles*: dividen la distribución en cien partes
      - El percentil *P* es un valor de manera que al menos *P* por ciento de los valores tienen este valor o menos, y como máximo *100-P* por ciento toman este valor o más
      - La mediana es lo mismo que el percentil 50

Estadísticas descriptivas

- Dispersión
  - Rango intercuartílico (*interquartile range*, *IQR*)
    - Medida habitual de variabilidad
    - Diferencia entre el percentil 75 (*Q3*) y el percentil 25 (*Q1*)

$$IQR = Q_3 - Q_1$$

    - Muestra el rango cubierto por la mitad central de los datos
    - Menos sensible a valores extremos que la varianza y la desviación estándar

Estadísticas descriptivas

- Dispersión
  - Desviación estándar (*standard deviation*)
    - Raíz cuadrada de la varianza
    - Más fácil de interpretar que la varianza, al estar en la misma escala
    - Aunque menos intuitiva es más usada que la desviación media
    - Especialmente sensible a valores extremos (igual que la varianza)

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Estadísticas descriptivas

¡Practiquemos!

https://bit.ly/3121X7m

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - **Visualización**
- Aprendizaje automático
  - Datos
  - Características
  - Algoritmos
- …y para saber más

Visualización

- Definición
  - Visualizar los datos permite resaltar sus principales características
  - Formas de presentar los datos
    - Textual
    - Tabular
    - Gráfica
  - La representación gráfica es atractiva y fácil de entender
    - Explorar los datos
    - Comunicar los datos (no solo a expertos)

Visualización

- Las técnicas de visualización pueden proporcionar una respuesta rápida a muchas preguntas importantes
  - ¿Qué rango cubren las observaciones?
  - ¿Cuál es la tendencia central?
  - ¿La distribución es simétrica o hay asimetría en alguna dirección?
  - ¿Hay evidencia de bimodalidad?
  - ¿Hay valores extremos significativos?
  - ...

Visualización

- Hay múltiples tipos de diagramas para distintos objetivos:
  - Diagrama de barras (ranking)
  - Histograma (distribución)
  - Diagrama de densidad (distribución)
  - Diagrama de líneas (evolución)
  - Diagrama de dispersión (correlación)
  - Mapa de calor (correlación)
  - Diagrama de caja (distribución y ranking)
  - Diagrama de violín (distribución)
  - Nube de palabras (ranking)
  - …

Visualización

- Diagrama de barras (*bar chart*)
  - Útiles para visualizar distribuciones de valores discretos o categoriales
  - Representa gráficamente la comparación entre categorías de datos

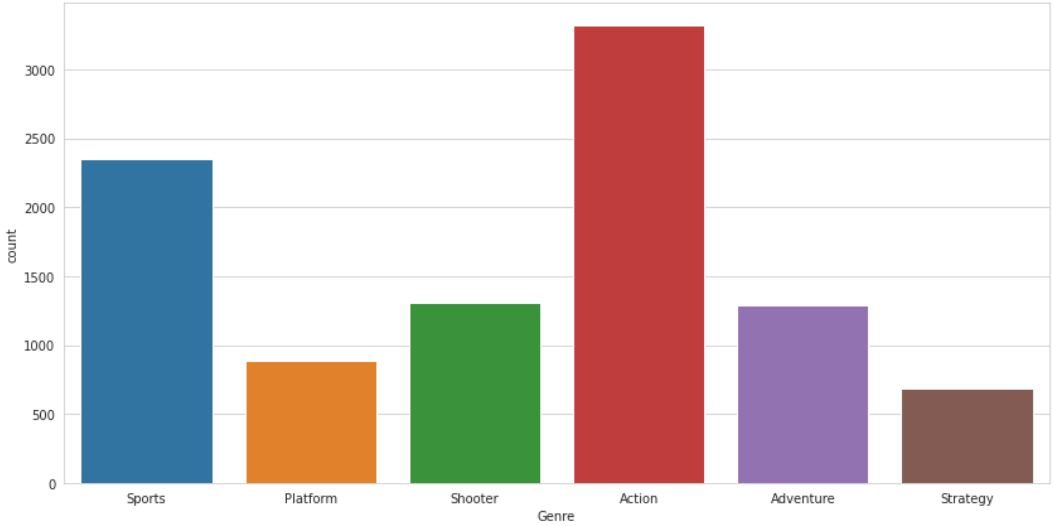

Visualización

- Histograma (*histogram*)
  - Tipo de gráfico de barras para visualizar distribuciones de valores numéricos
  - Indica el número de observaciones que caen dentro de un rango de valores (*bin*)

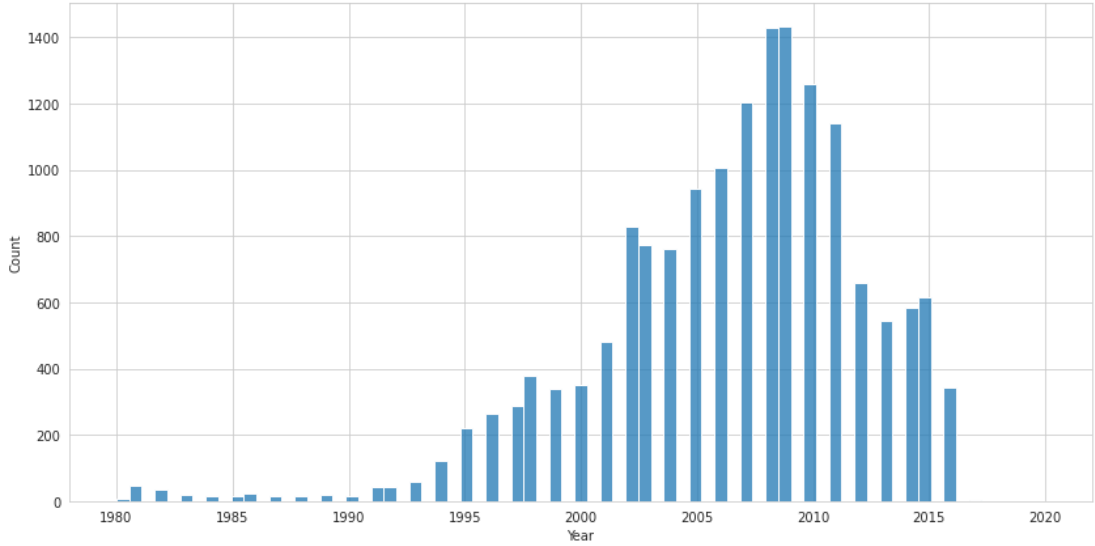

Visualización

- Diagrama de densidad (*density plot*)
  - Es una variante del histograma que usa un kernel gaussiano para suavizar los valores
  - Ofrecen una mejor visión de la forma de la distribución

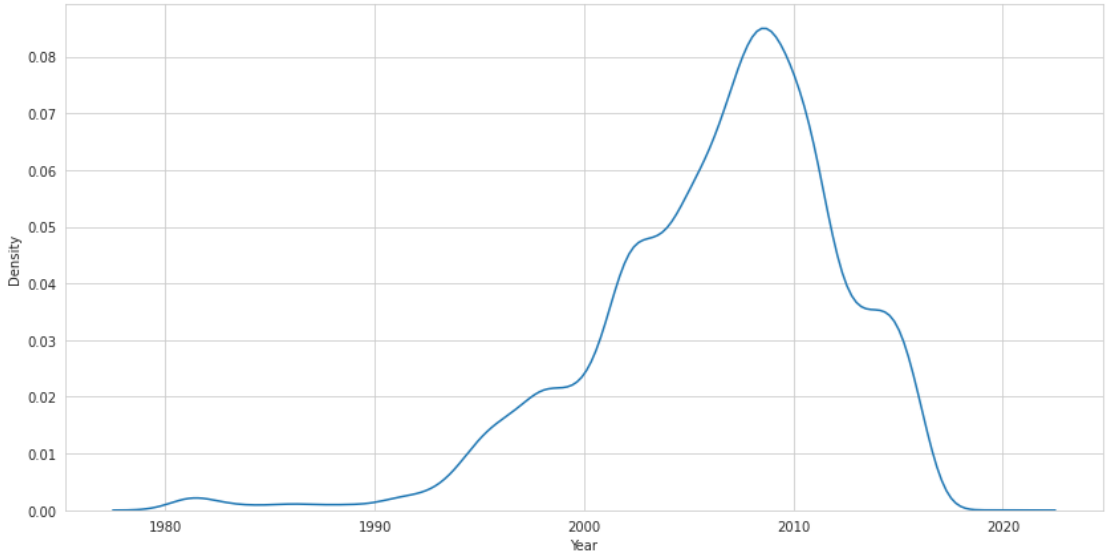

Visualización

- Diagrama de líneas (*line chart*)
  - Útil para visualizar tendencias (muy habituales en series temporales)
  - Muestra los datos como puntos unidos por líneas rectas

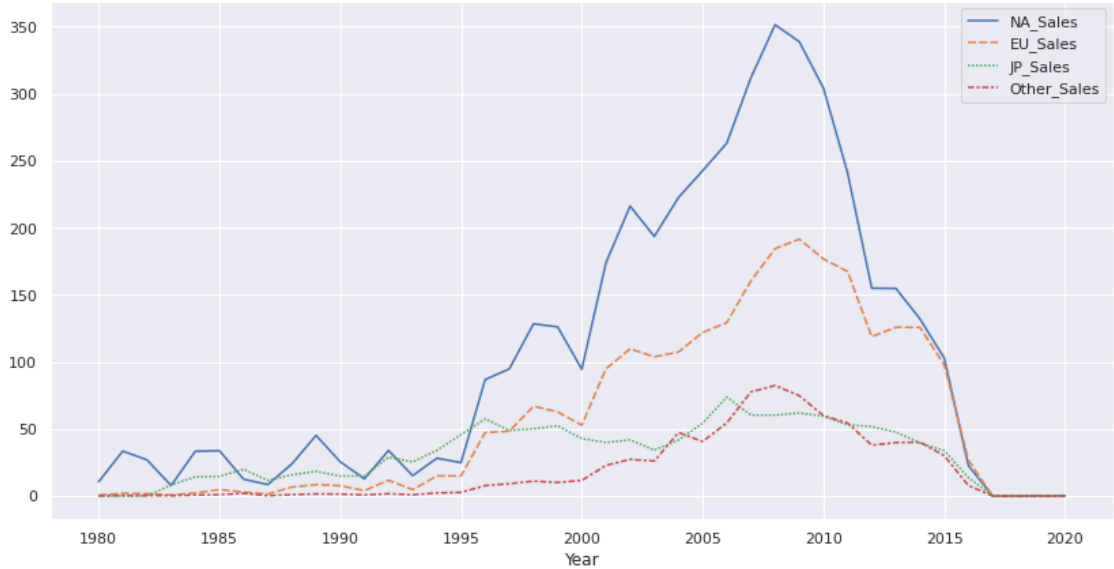

Visualización

- Diagrama de dispersión (*scatter plot*)
  - Útil para identificar relaciones, patrones o tendencias entre dos valores numéricos (bivariado)
  - Visualizar agrupaciones de datos
  - Identificar de outliers
  - Explorar correlaciones

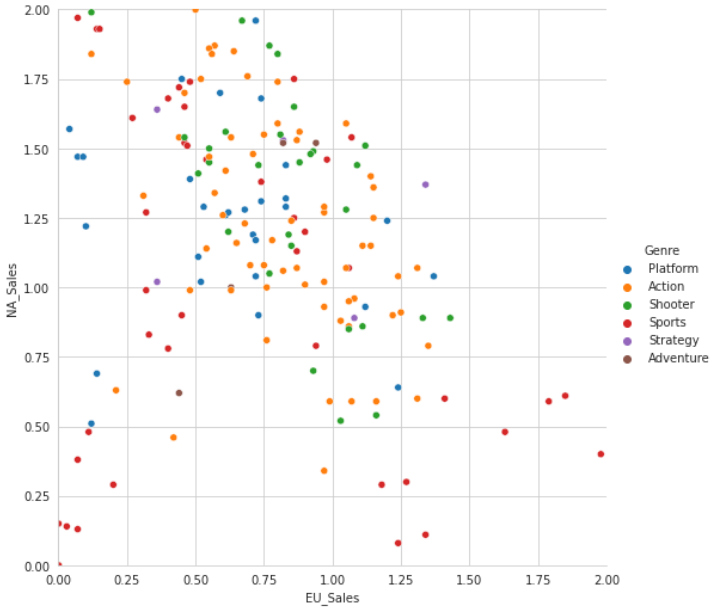

Visualización

- Diagrama de dispersión (*scatter plot*)
  - Dos atributos están correlacionados si uno implica el otro
    - Positiva: cuando uno aumenta el otro también
    - Negativa: cuando uno aumenta el otro disminuye
    - Neutral: no hay correlación

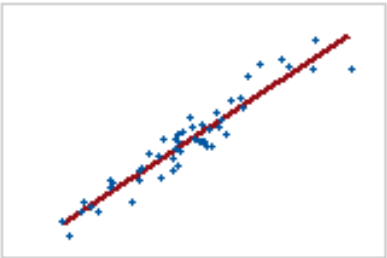

Correlación positiva

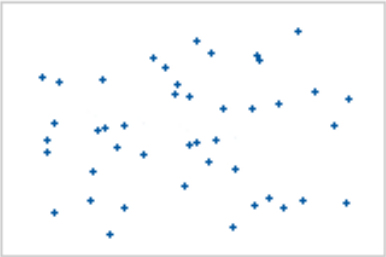

Sin correlación

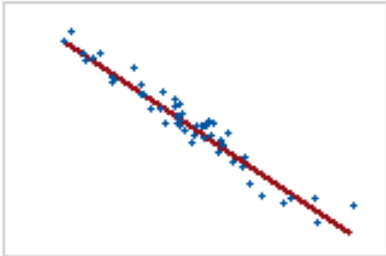

Correlación negativa

Visualización

- Diagrama de dispersión (*scatter plot*)
  - Correlación no implica causalidad

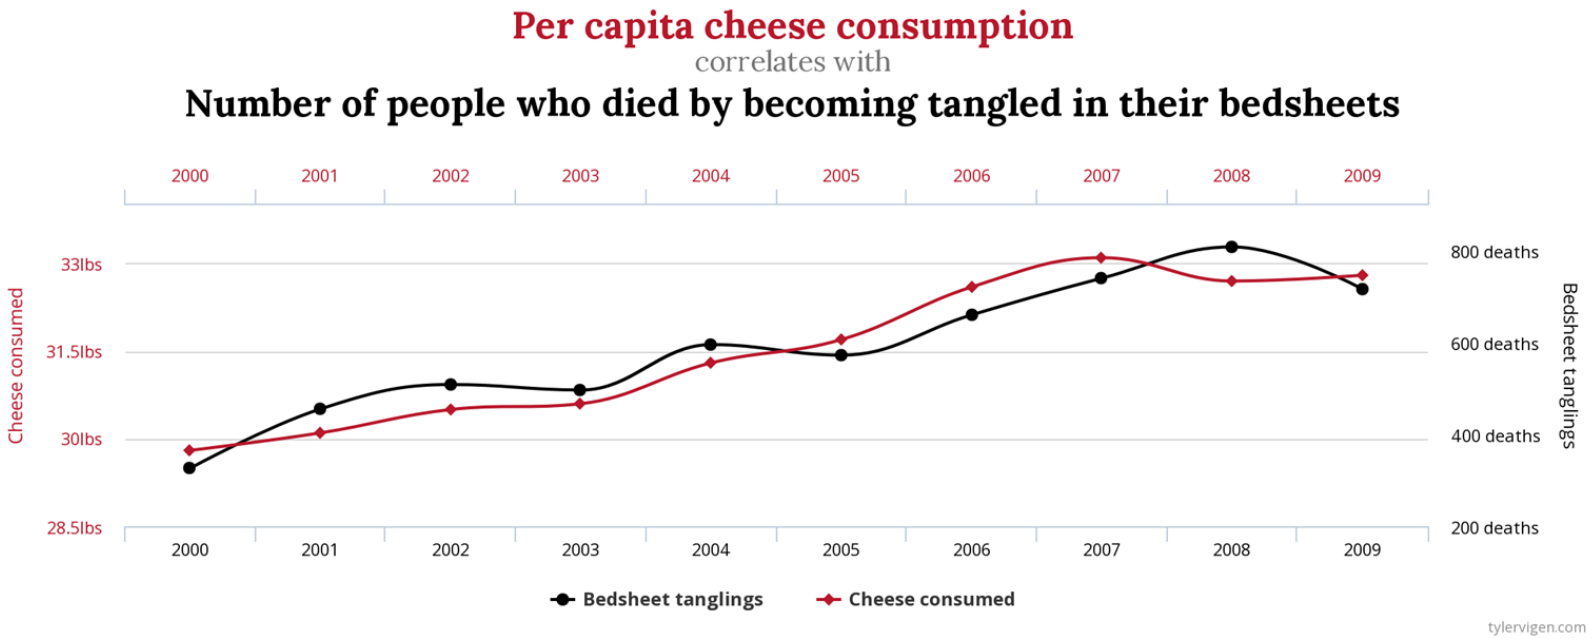

Visualización

- Mapa de calor (*heatmap*)
  - Visualizar datos mediante códigos de colores en dos dimensiones (útil para correlaciones)
  - El tono y/o la intensidad indica cómo varían los datos en el espacio

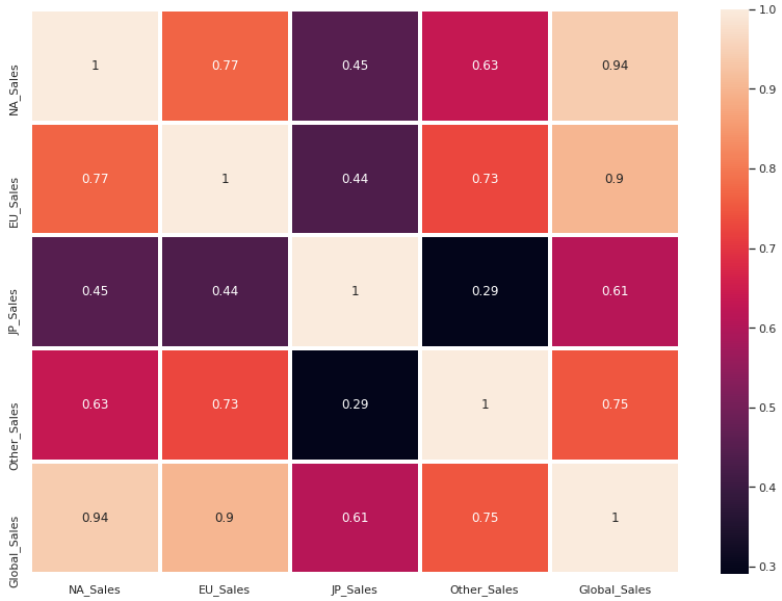

Visualización

- Diagrama de caja (*box plot*)
  - Describe grupos de datos numéricos mediante cuartiles
  - Útil para datos que no siguen una distribución normal

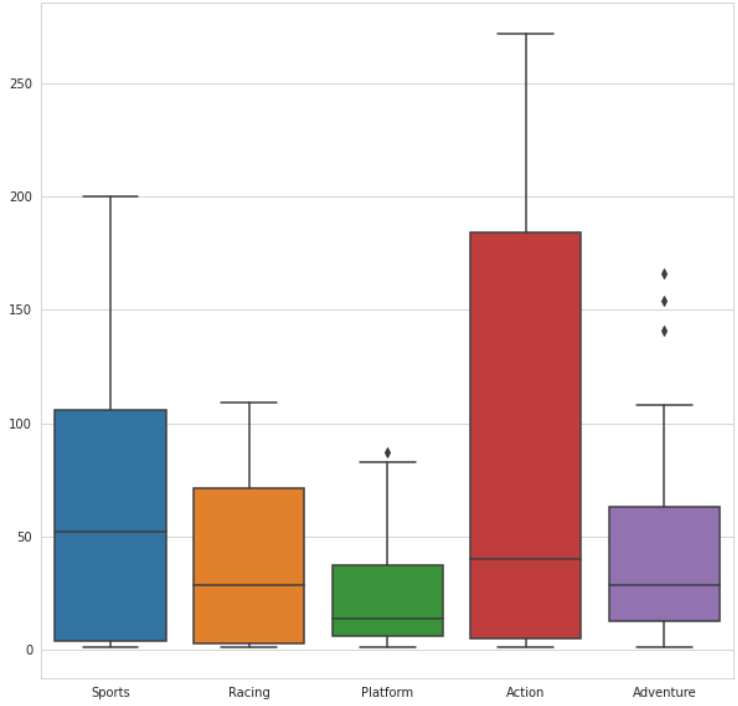

Visualización

- Diagrama de caja (*box plot*)
  - Resumen de cinco números
    - Extremo inferior
    - Cuartil inferior (Q1)
    - Mediana
    - Cuartil superior (Q3)
    - Extremo superior
  - *Outliers*
    - Por debajo de Q1 - 1.5 * IQR
    - Por encima de Q3 + 1.5 * IQR

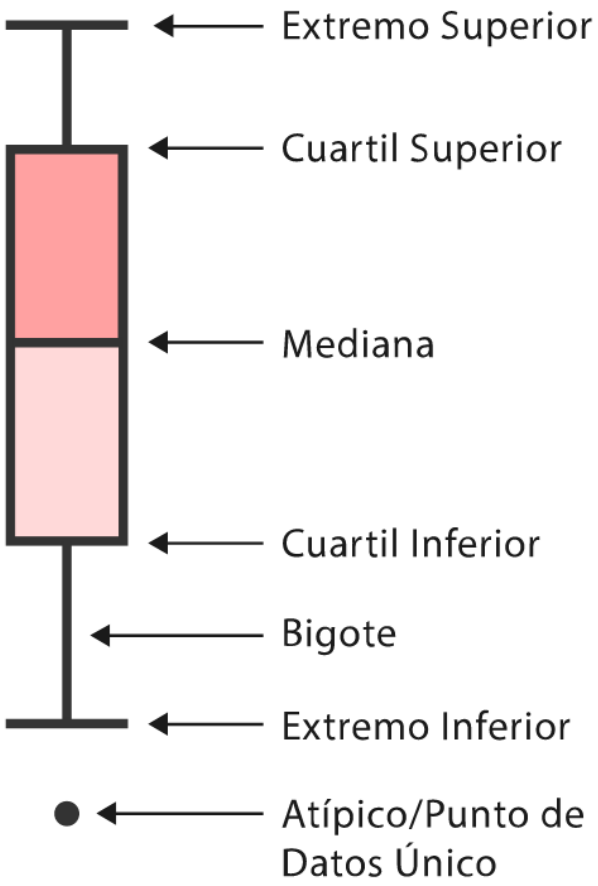

Visualización

- Diagrama de violín (*violin plot*)
  - Proporciona la información de un diagrama de caja y además la distribución de valores
  - Adecuados cuando tenemos muchos valores y no se pueden visualizar individualmente

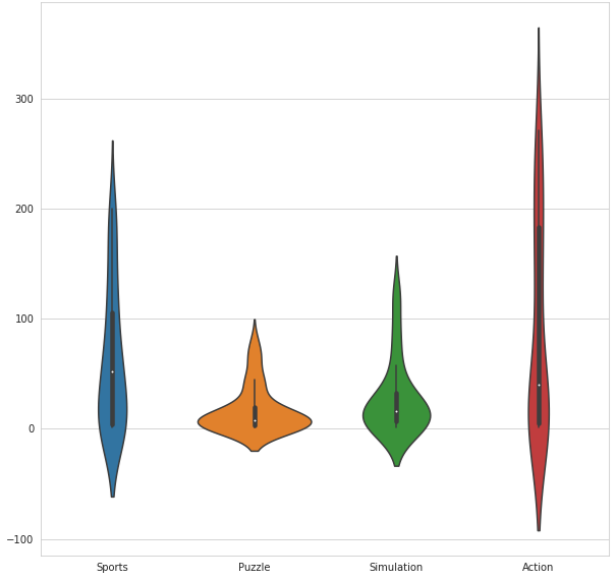

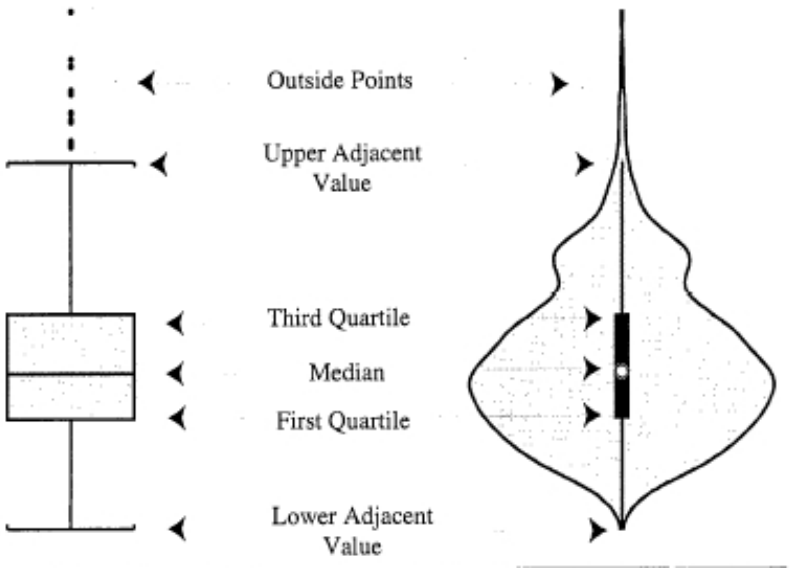

Visualización

- Nube de palabras (*word cloud*)
  - Representación visual de las palabras que conforman un texto
  - El tamaño es mayor para las palabras más frecuentes

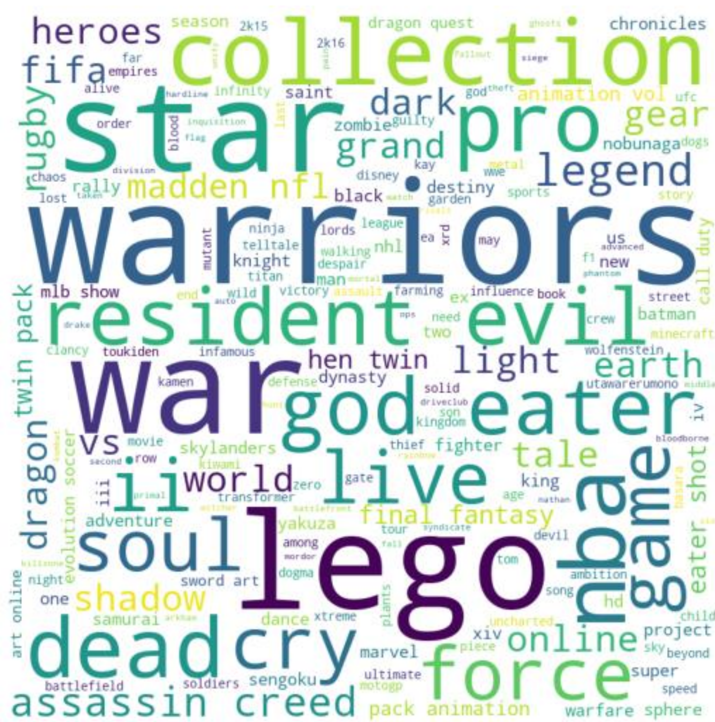

¡Practiquemos!

https://bit.ly/38ZtUPd

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- **Aprendizaje automático**
  - Datos
  - Características
  - Algoritmos
- …y para saber más

Aprendizaje automático

- También llamado *machine learning*
- Rama de la Inteligencia Artificial
- Objetivos
  - Desarrollar técnicas que permitan a los ordenadores aprender a partir de datos
  - Generalizar a partir de la experiencia (inducción) y construir un modelo

> *"Se dice que un programa de ordenador aprende a partir de una experiencia E con respecto a una tarea T y una medida de rendimiento P, si su rendimiento en la tarea T, medida usando P, mejora con la experiencia E"*, Tom M. Mitchell

Aprendizaje automático

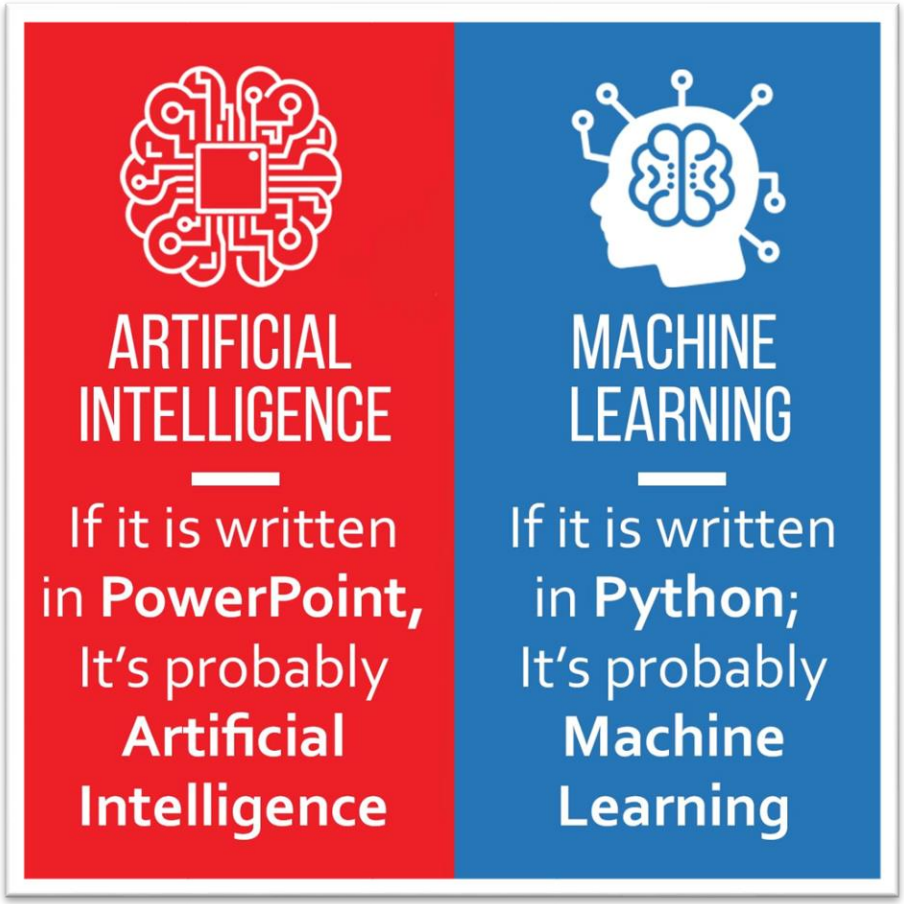

Aprendizaje automático

- Componentes de un sistema de aprendizaje automático
  - Datos
    - Conjunto de muestras que se utilizan para entrenar/evaluar el sistema
  - Características
    - Atributos que representan a cada una de las muestras del conjunto de datos
  - Algoritmos
    - Operaciones que permiten aprender a partir de las *características* obtenidas de los *datos* de entrenamiento para generar un *modelo*

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - **Datos**
  - Características
  - Algoritmos
- …y para saber más

Datos

- Los datos son colecciones de objetos
  - Pacientes de un hospital
  - Clientes de una operadora telefónica
  - Viajes en tren de Barcelona a Madrid
  - Accesos a un servidor Web
  - Animales de un zoo
  - Pisos vendidos en una zona
  - …
- Son el *combustible* de los sistemas de aprendizaje automático
- Al conjunto de datos disponible en una aplicación se le llama *dataset*

Datos

- Hay que invertir mucho esfuerzo en garantizar que los datos son de calidad
  - Obtener un conjunto amplio
  - Que sea representativo
  - Eliminar falsas observaciones
  - Limpiar
  - Dar formato
  - …
- No importa lo sofisticados que sean los algoritmos si los datos no son adecuados

Datos

We don't have better algorithms.
We just have more data.

Peter Norving (Google Inc.)

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - Datos
  - **Características**
  - Algoritmos
- …y para saber más

Características

- Cada dato (objeto) es descrito por un número de características/atributos (*features*) que representan sus propiedades
  - Ej: para una persona: color de ojos, altura, peso, edad, …
- Dos tipos fundamentales de características
  - Discretas
    - Contienen etiquetas que representan categorías
    - Ej: color de un objeto, código postal, aprobado/suspendido, …
  - Continuas
    - Toman valores numéricos
    - Ej: número de hijos, altura, edad, peso, …

Características

- Un conjunto de datos se representa habitualmente como una tabla o una serie de vectores de características
  - Cada columna es una *característica*
  - Cada fila es una *instancia* (objeto)

Características

Instancias

Id	Reembolso	Estado Civil	Salario	Fraude
1	Sí	Soltero	125.000€	No
2	No	Casado	100.000€	No
3	No	Soltero	70.000€	No
4	No	Divorciado	95.000€	Sí
…	…	…	…	…

Características

- Datos etiquetados (*labelled*)
  - Hay una característica especial para cada instancia llamada *clase*

clase

Id	Reembolso	Estado Civil	Salario	Fraude
1	Sí	Soltero	125.000€	No
2	No	Casado	100.000€	No
3	No	Soltero	70.000€	No
…	…	…	…	…

- Datos no etiquetados (*unlabelled*)
  - No hay una *clase* definida

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - Datos
  - Características
  - **Algoritmos**
- …y para saber más

Algoritmos

- Aprendizaje supervisado (métodos predictivos)
  - Utilizan datos *etiquetados*
  - Usar algunas variables para predecir valores futuros o no conocidos de otras variables
    - Clasificación
    - Regresión
- Aprendizaje no supervisado (métodos descriptivos)
  - Utilizan datos *no etiquetados*
  - Encontrar patrones interpretables por un humano que describan los datos
    - Agrupamiento
    - Reglas de asociación

Algoritmos

- Clasificación
  - Trabaja con datos *etiquetados*
  - El atributo *clase* es de tipo *discreto*
    - Contiene un conjunto de etiquetas como posibles valores
    - Ej: `{positivo, negativo, neutro}`,`{hombre, mujer}`, …
  - El objetivo es predecir el valor del atributo *clase* para instancias no vistas con anterioridad
  - Debemos encontrar un modelo para el atributo *clase* en función de los valores de los otros atributos

Algoritmos

- Clasificación
  - Conjunto de entrenamiento (*training set*)
    - Colección de instancias inicial, con sus clases ya asignadas
    - Se utiliza para construir el modelo
  - Conjunto de validación (*validation set*)
    - Colección de instancias, con sus clases ya asignadas
    - Se utiliza para ajustar los parámetros del modelo y seleccionar la mejor configuración
    - No siempre es necesario
  - Conjunto de evaluación (*test set*)
    - Colección de instancias, con sus clases ya asignadas
    - Se utiliza para validar el modelo, comparando las clases preasignadas con las que el modelo produce

Algoritmos

Re.	Estado	Salario	Fraude
Sí	Soltero	125.000€	No
No	Casado	100.000€	No
No	Soltero	70.000€	No
Sí	Casado	120.000€	No
No	Divorciado	95.000€	Sí
No	Casado	60.000€	No
…	…	…	…

Conjunto de entrenamiento

Re.	Estado	Salario	Fraude
No	Soltero	75.000€	?
Sí	Casado	50.000€	?
No	Casado	150.000€	?
Sí	Divorciado	90.000€	?
…	…	…	…

Conjunto de evaluación

Algoritmos

Re.	Estado	Salario	Fraude
Sí	Soltero	125.000€	No
No	Casado	100.000€	No
No	Soltero	70.000€	No
Sí	Casado	120.000€	No
No	Divorciado	95.000€	Sí
No	Casado	60.000€	No
…	…	…	…

Conjunto de entrenamiento

Clase a predecir

Re.	Estado	Salario	Fraude
No	Soltero	75.000€	?
Sí	Casado	50.000€	?
No	Casado	150.000€	?
Sí	Divorciado	90.000€	?
…	…	…	…

Conjunto de evaluación

Algoritmos

Re.	Estado	Salario	Fraude
Sí	Soltero	125.000€	No
No	Casado	100.000€	No
No	Soltero	70.000€	No
Sí	Casado	120.000€	No
No	Divorciado	95.000€	Sí
No	Casado	60.000€	No
…	…	…	…

Re.	Estado	Salario	Fraude
No	Soltero	75.000€	?
Sí	Casado	50.000€	?
No	Casado	150.000€	?
Sí	Divorciado	90.000€	?
…	…	…	…

Algoritmos

Re.	Estado	Salario	Fraude
Sí	Soltero	125.000€	No
No	Casado	100.000€	No
No	Soltero	70.000€	No
Sí	Casado	120.000€	No
No	Divorciado	95.000€	Sí
No	Casado	60.000€	No
…	…	…	…

Re.	Estado	Salario	Fraude
No	Soltero	75.000€	?
Sí	Casado	50.000€	?
No	Casado	150.000€	?
Sí	Divorciado	90.000€	?
…	…	…	…

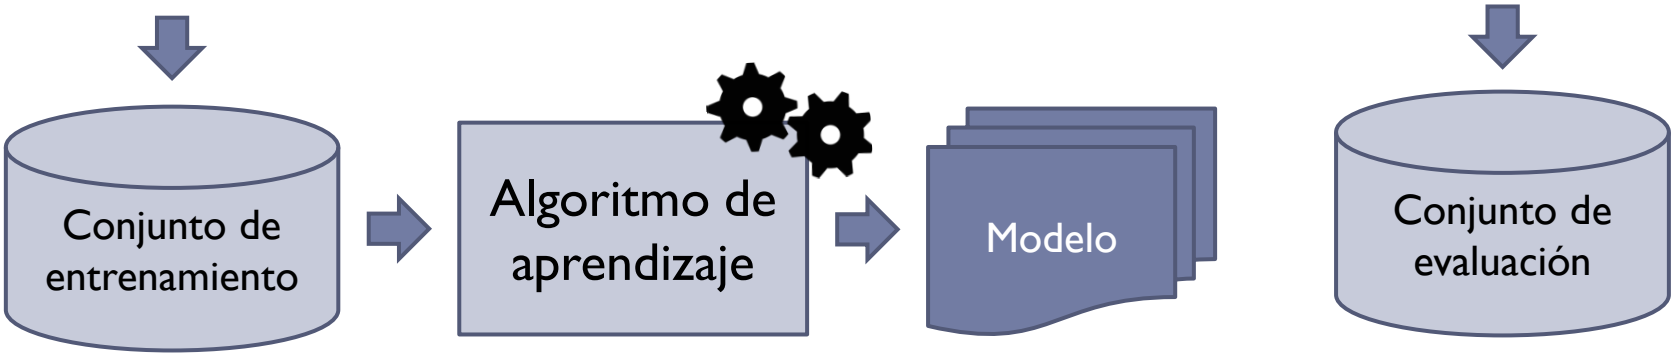

Algoritmos

Re.	Estado	Salario	Fraude
Sí	Soltero	125.000€	No
No	Casado	100.000€	No
No	Soltero	70.000€	No
Sí	Casado	120.000€	No
No	Divorciado	95.000€	Sí
No	Casado	60.000€	No
…	…	…	…

Re.	Estado	Salario	Fraude
No	Soltero	75.000€	?
Sí	Casado	50.000€	?
No	Casado	150.000€	?
Sí	Divorciado	90.000€	?
…	…	…	…

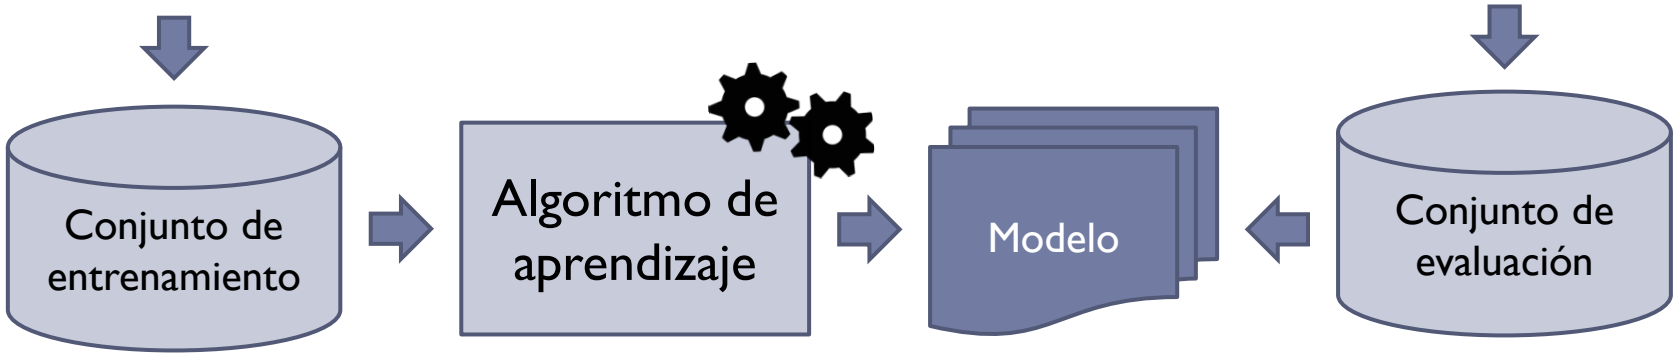

Algoritmos

Re.	Estado	Salario	Fraude
Sí	Soltero	125.000€	No
No	Casado	100.000€	No
No	Soltero	70.000€	No
Sí	Casado	120.000€	No
No	Divorciado	95.000€	Sí
No	Casado	60.000€	No
…	…	…	…

Re.	Estado	Salario	Fraude
No	Soltero	75.000€	No
Sí	Casado	50.000€	Sí
No	Casado	150.000€	No
Sí	Divorciado	90.000€	No
…	…	…	…

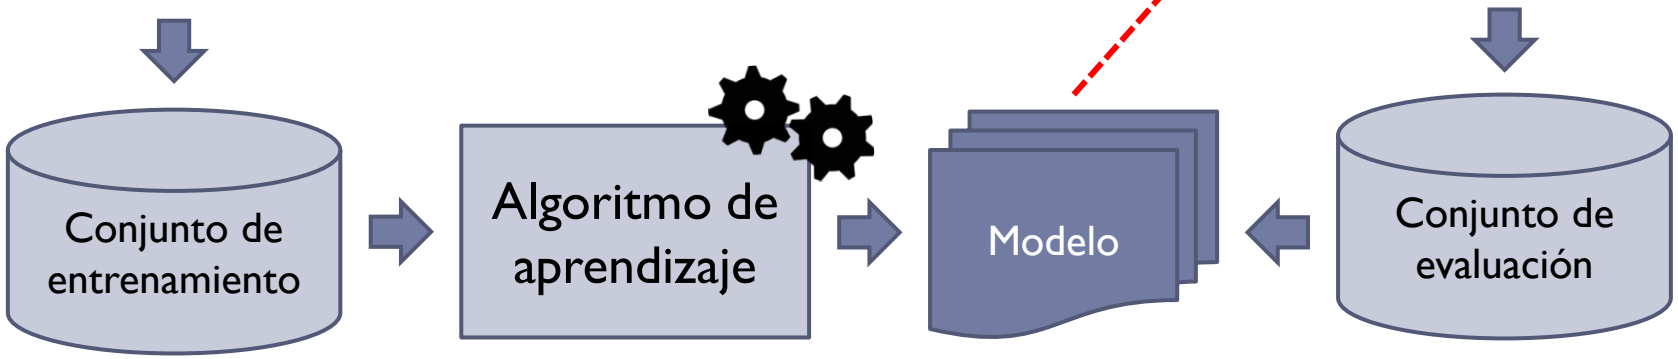

Algoritmos

- Clasificación
  - Ejemplo de aplicación
    - Marketing directo
      - Objetivo
        - Reducir el coste de envío de correo seleccionando un conjunto de clientes que sean candidatos a comprar un nuevo modelo de teléfono móvil
      - Aproximación
        - Usar datos de un producto similar existente anteriormente
        - Sabemos qué cliente lo compró y quién no
        - La decisión `{comprará, no_comprará}` constituye el atributo *clase* que queremos predecir
        - Recolectar información demográfica, de estilo de vida, tipo de negocio, salario, etc. para cada cliente potencial
        - Usar esa información como *características* de entrada para entrenar el clasificador

Algoritmos

- Clasificación
  - Ejemplo de aplicación
    - Fidelización de clientes
      - Objetivo
        - Predecir cuándo una compañía puede perder un cliente
      - Aproximación
        - Usar instancias de transacciones de clientes pasados y presentes
        - Con qué frecuencia llama el cliente, dónde llama, a qué hora del día, situación económica, estado civil, etc.
        - Etiquetar a los clientes como `{leal, desleal}` (ésta será la *clase*)
        - Encontrar un modelo para predecir la lealtad de los clientes

Algoritmos

- Clasificación
  - Existen numerosos algoritmos de clasificación
  - Algunos funcionan mejor para determinadas tareas
    - Dependiendo del número de instancias
    - Dependiendo del número de características
  - Tipos
    - Árboles de decisión
    - Razonamiento basado en ejemplos
    - Redes neuronales
    - Bayesianos
    - Separadores lineales
    - …

Algoritmos

- *k-Nearest Neighbors* (k-NN)
  - Idea intuitiva: "si anda como una pato y grazna como un pato, probablemente sea un pato"

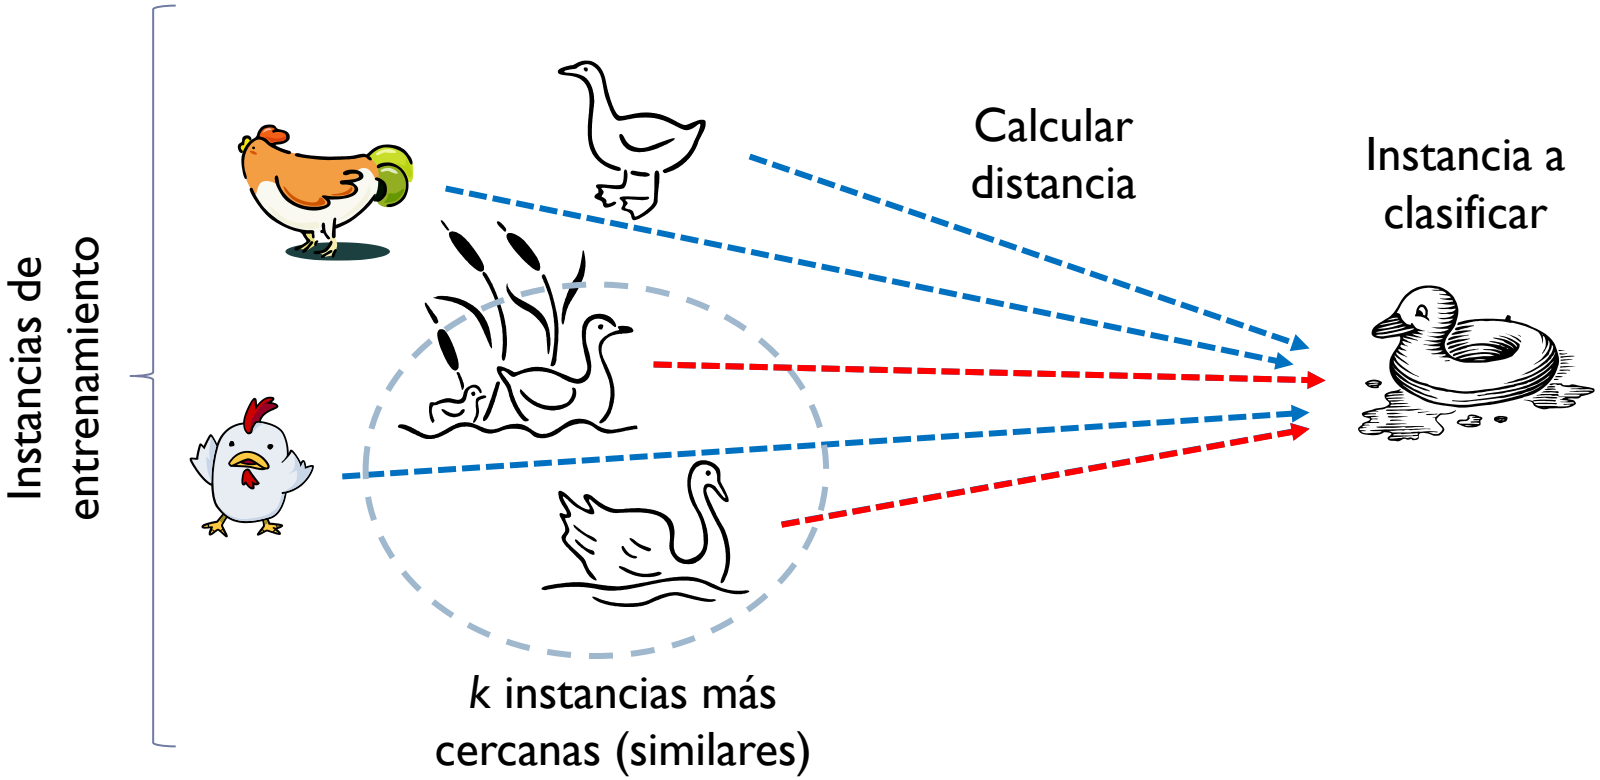

Algoritmos

- *Deep Neural Networks* (Redes neuronales profundas)
  - Separan las muestras en un espacio multidimensional

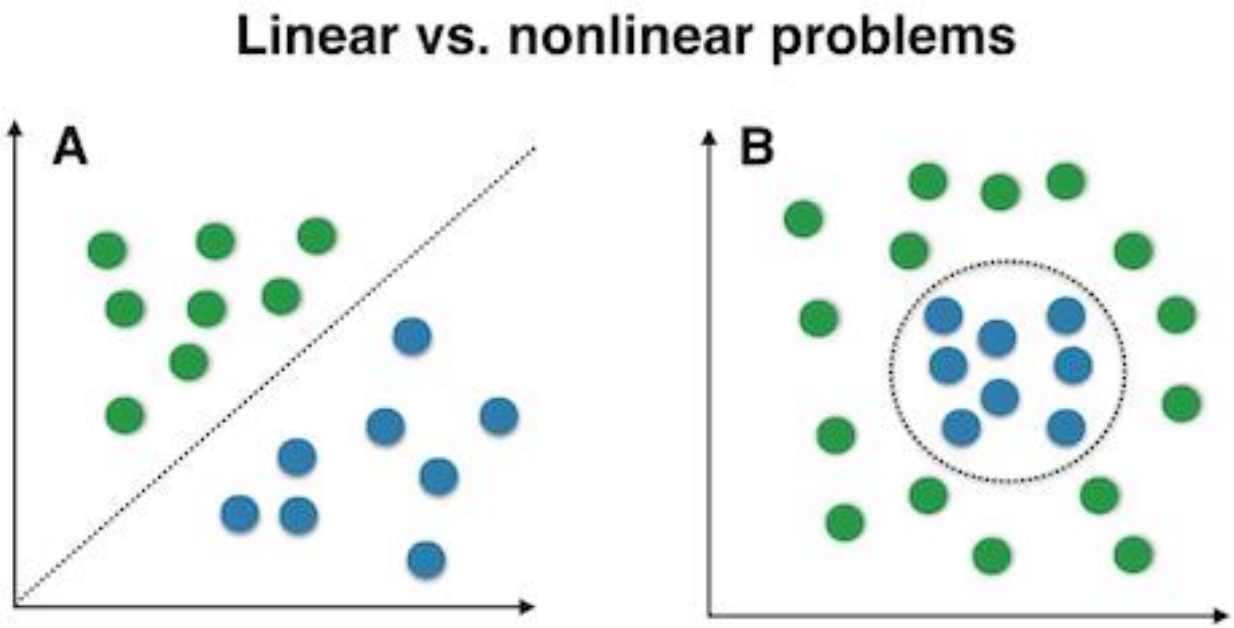

Algoritmos

- Regresión
  - Trabaja con datos etiquetados (como la clasificación)
  - El atributo *clase* es de tipo continuo
    - Contiene un conjunto de valores numéricos
    - Ej: precio estimado de una casa, de una acción, ….
  - Debemos encontrar un modelo para el atributo *clase* en función de los valores de los otros atributos
  - El objetivo es predecir el valor del atributo continuo *clase* para instancias no vistas con anterioridad

Algoritmos

- Regresión
  - Emplea los mismos conjuntos de datos que para la clasificación
    - Conjunto de entrenamiento
    - Conjunto de validación
    - Conjunto de evaluación
  - Algoritmos
    - Perceptrón multicapa
    - k-NN
    - Máquinas de Vectores de Soporte (SVM)
    - Árboles de decisión (M5P)
    - …

Algoritmos

- Regresión
  - Ejemplos de aplicación
    - Predecir el número de ventas de un nuevo producto basado en los gastos de publicidad
    - Predecir la velocidad del viento como una función de la temperatura, humedad, presión del aire, etc.
    - Predicción de series temporales en índices del mercado de valores

Algoritmos

- Agrupamiento
  - También conocido como *clustering*
  - Trabaja con datos *no etiquetados*
  - El objetivo es encontrar agrupamientos (*clusters*) en los datos (instancias) de manera que
    - Las instancias de un *cluster* se parecen más entre ellas
    - Las instancias en distintos *clusters* se parecen menos entre ellas
  - Es necesaria una medida de similitud entre instancias
    - Ej: la distancia euclídea si los atributos son numéricos

Algoritmos

- Agrupamiento

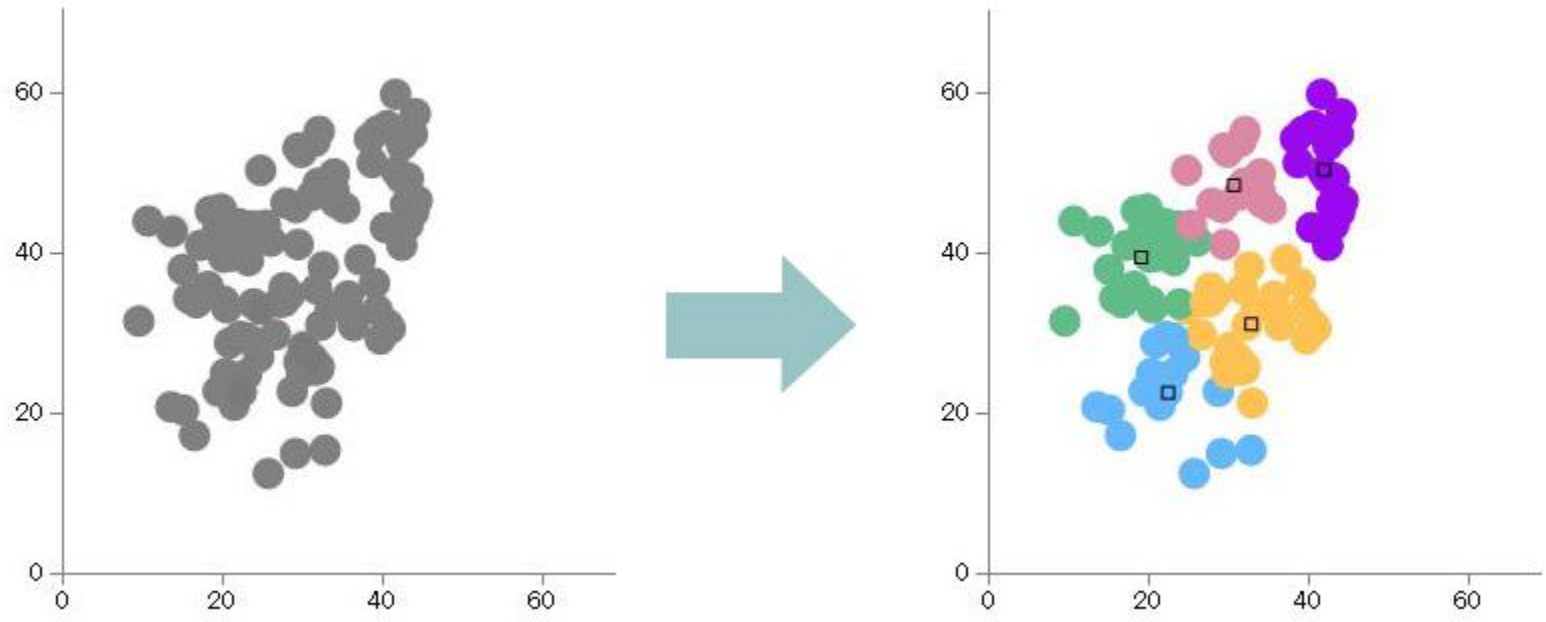

Algoritmos

- Agrupamiento
  - Ejemplo de aplicación
    - Segmentación del mercado
      - Objetivo
        - Dividir el mercado en distintos subconjuntos de clientes
        - Cualquier subconjunto puede ser seleccionado como mercado objetivo a alcanzar con una aproximación de marketing distinta
      - Aproximación
        - Recolectar atributos de los clientes basados en su información geográfica y de estilo de vida
        - Encontrar *clusters* de clientes similares
        - Medir la calidad del *cluster* observando los patrones de compra de clientes en el mismo *cluster* con respecto a otros en distintos *clusters*

Algoritmos

- Agrupamiento
  - ¿Cuál es el agrupamiento natural de estos objetos?

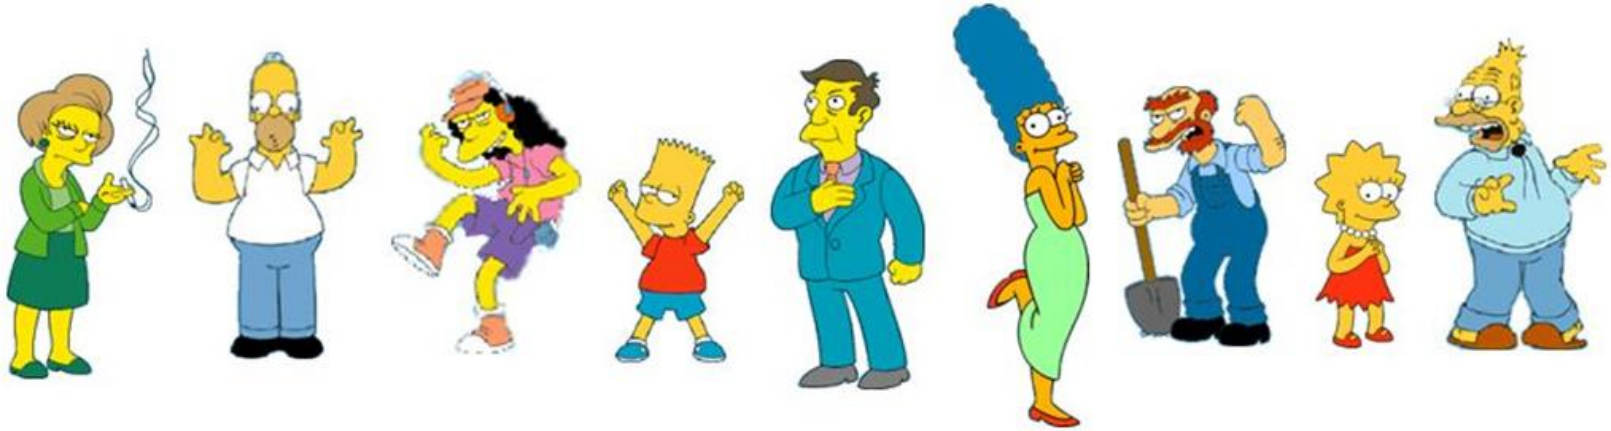

Algoritmos

- Agrupamiento
  - ¿Cuál es el agrupamiento natural de estos objetos?
    - Agrupar es una tarea subjetiva
    - Las características y las medidas de similitud son importantes

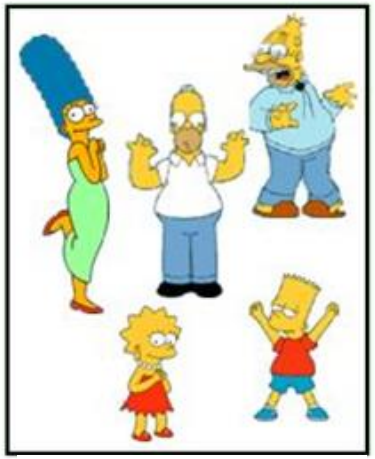

Familia Simpson

Empleados escuela

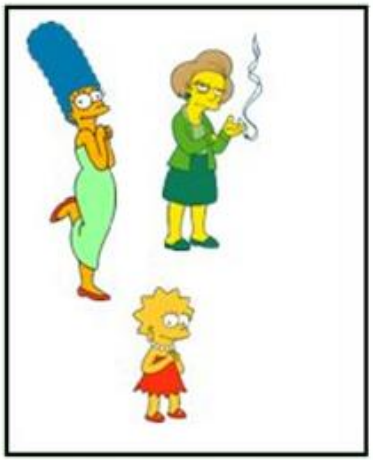

Mujeres

Hombres

Algoritmos

- Agrupamiento
  - Algoritmos
    - K-means
    - Expectation Maximisation (EM)
    - Cobweb
    - …
  - En algunos algoritmos es necesario definir el número de *clusters*

Algoritmos

- Reglas de asociación
  - Trabaja con datos no etiquetados (como el *clustering*)
  - Objetivo: obtener unas reglas de dependencia para predecir la ocurrencia de un ítem basado en la ocurrencia de otros ítems
  - Uso habitual para análisis de afinidad (*market basket analysis*)
    - Si conocemos las compras hechas por todos los clientes durante un periodo, podemos encontrar relaciones entre dichos productos

```
SI queso Y leche ENTONCES pan (probabilidad = 0,7)
```

Algoritmos

- Reglas de asociación
  - Partimos de un conjunto de instancias, cada una con una serie de elementos de una colección

Conjunto de instancias

Id	Ítems
1	pan, refresco, leche
2	cerveza, pan
3	cerveza, refresco, pañales, leche
4	cerveza, pan, pañales, leche
5	refresco, pañales, leche

Reglas descubiertas

{leche} → {refresco}
{pañales, leche} → {cerveza}

Algoritmos

- Reglas de asociación
  - Ejemplos de aplicación
    - Gestión de un supermercado
      - Objetivo
        - Identificar los ítems que se suelen compran juntos por los clientes
      - Aproximación
        - Procesar los datos de punto de venta recolectados en las cajas para encontrar dependencias entre los ítems
        - Regla clásica
          - La parábola de los pañales y la cerveza
          - Si un cliente compra pañales y leche, es muy probable que compre cerveza

Algoritmos

- Reglas de asociación
  - Ejemplos de aplicación
    - Manejo de inventario
      - Objetivo
        - Una compañía de reparaciones quiere anticipar la naturaleza de las reparaciones de sus productos
        - Mantener los vehículos de servicio equipados con los componentes adecuados para reducir el número de visitas a un domicilio
      - Aproximación
        - Procesar los datos sobre herramientas y componentes necesarios en reparaciones previas en diferentes localizaciones de consumidores
        - Descubrir la coocurrencia de patrones

¡Practiquemos!

https://bit.ly/30XgtL8

Contenidos

- La importancia de los datos
- De los datos al conocimiento
- Análisis de datos exploratorio
  - Estadísticas descriptivas
  - Visualización
- Aprendizaje automático
  - Datos
  - Características
  - Algoritmos
- **…y para saber más**

… y para saber más

- Webs
  - Towards Data Science
  - KDnuggets
  - Kaggle competitions
  - Coursera
- YouTube
  - Dot CSV
- Cursos (¡Ojo! Publicidad encubierta)
  - "*Big Data: fundamentos tecnológicos y aplicaciones prácticas*", curso de verano de la UA
  - "Máster Universitario en Ciencia de Datos", título de la UA

Ejercicios

¡Practiquemos!

https://bit.ly/2P2rqsv

@d_tomas

David Tomás Díaz

CC BY SA